

Análise de Cluster na Discografia de Taylor Swift: Explorando Padrões com Dados do Spotify

Antonia Xavier

2024

Resumo

A análise de agrupamento é uma técnica estatística crucial para identificar padrões e grupos de dados semelhantes, sendo amplamente utilizada em diversas áreas, inclusive nas artes. Este estudo aplica métodos de análise de agrupamento não supervisionada à obra de Taylor Swift, com o objetivo de investigar mudanças estilísticas e temáticas ao longo de sua carreira. A partir de dados extraídos da API do Spotify, utilizamos características técnicas das músicas, como energia, dançabilidade, volume e tempo, para formar clusters. A análise é conduzida em duas etapas: inicialmente, um método hierárquico é utilizado para explorar a estrutura dos dados, seguido pelo algoritmo k-means para realizar o agrupamento definitivo. Este estudo visa oferecer uma compreensão mais profunda da evolução artística de Taylor Swift, com ênfase nas transformações estilísticas e temáticas que marcam sua trajetória musical.

Palavras-chaves: k-means, agrupamento, análise de cluster, análise de dados, spotify, taylor swift, análise de dados dados musicais

1 Introdução

A análise de agrupamento é uma das técnicas estatísticas multivariadas mais difundidas, possibilitando organizar dados em grupos que compartilham características semelhantes, o que facilita a construção de hipóteses com base em informações subjetivas e permite explorar múltiplas dimensões dos dados (DUARTE, 2021, p. 15). Em contextos artísticos, essa técnica viabiliza a identificação de padrões dos mais diversos tipos com base nos dados.

Neste trabalho, utiliza-se a análise de agrupamento para investigar a obra musical de Taylor Swift. Artista amplamente reconhecida e escolhida como “Pessoa do Ano” pela revista Time em 2023, sendo a primeira "Pessoa do Ano" escolhida por suas contribuições ao mundo artístico. Taylor Swift destaca-se tanto como uma força arquitetônica que molda a nova era da música, bem como uma potência econômica, alterando as próprias dinâmicas da indústria musical (FINK, 2024). Com um repertório vasto e diversificado, a artista

tornou-se a mais ouvida da história do Spotify, segundo a CNN, reafirmando seu impacto cultural.

Dessa forma, Taylor Swift representa um caso de estudo ideal para a aplicação da análise de agrupamento, uma vez que sua obra abrange diferentes estilos e fases criativas que evoluíram ao longo de sua carreira. O objetivo deste estudo é aplicar o método k-means para classificar as músicas de Taylor Swift com base em características técnicas e métricas fornecidas pela plataforma Spotify. A proposta é explorar se é possível identificar padrões e conexões entre as músicas, capturando elementos subjetivos a partir de uma análise fundamentada em critérios objetivos.

2 Metodologia

2.1 Base de dados

Os dados foram obtidos por meio da API do Spotify, utilizando o pacote do R `spotifyR`. Para acessar esses dados, foi necessário criar uma conta no Spotify for Developers com um e-mail ativo e aceitar os termos de uso da plataforma.

Com o pacote `spotifyR`, utilizamos o comando `get_artist_audio_features`, que extrai dados e metadados de todas as músicas de um artista específico, abrangendo músicas presentes em álbuns e singles. Esse procedimento resultou em um dataframe com 582 observações (músicas) e 39 variáveis.

Como nosso objetivo é agrupar músicas com características semelhantes, eliminamos algumas variáveis que não eram relevantes para a análise, como os IDs de artistas, álbuns e músicas, pois são identificadores únicos usados pelo Spotify apenas para controle interno. Da mesma forma, excluimos a variável "nome do artista", uma vez que focamos exclusivamente em músicas da Taylor Swift. Variáveis com estrutura de imagem, como a capa do álbum, e listas, como a dos países onde a música está disponível, também foram descartadas. Adicionalmente, removemos a variável que indica se a música é instrumental, pois sabemos que todas as músicas selecionadas são cantadas.

Optamos ainda por excluir variáveis que, conforme a análise exploratória, não apresentaram correlação significativa com as demais, como o tom e o acorde principal da música. Consideramos que essas variáveis poderiam introduzir ruído na análise. Após essas etapas, restaram 7 variáveis, todas numéricas, que atendem aos requisitos do modelo.

Taylor Swift é conhecida por lançar múltiplas versões de seus álbuns. Para uniformizar a base de dados, escolhemos a versão mais recente de cada um de seus álbuns de estúdio. A lista de álbuns incluídos é:

Tabela 1 – Versões dos álbuns utilizadas para análise

Nome da versão do álbum	Ano de lançamento
THE TORTURED POETS DEPARTMENT: THE ANTHOLOGY	2024
1989 (Taylor’s Version) [Deluxe]	2023
Speak Now (Taylor’s Version)	2023
Midnights (The Til Dawn Edition)	2023
Red (Taylor’s Version)	2021
Fearless (Taylor’s Version)	2021
evermore (deluxe version)	2021
folklore (deluxe version)	2020
Lover	2019
reputation	2017
Taylor Swift	2006

Fonte: Autor.

Assim, após essas considerações e modificações, decidimos trabalhar com as variáveis presentes na Tabela 2:

Tabela 2 – Descrição das Variáveis

Nome	Descrição	Formato	Valores Possíveis
Nome do álbum	Nome do álbum na plataforma	Categórico (Texto)	-
Nome da música	Nome da música na plataforma	Categórico (Texto)	-
Dançabilidade	Índice de dançabilidade da faixa	Numérico (Real)	0 a 1
Energia	Intensidade e atividade da faixa	Numérico (Real)	0 a 1
Volume	Altura média em decibéis	Numérico (Real)	-60 a 0 dB
Acústica	Confiança se é uma versão acústica	Numérico (Real)	0 a 1
Valência	Humor da música (triste a feliz)	Numérico (Real)	0 a 1
Tempo	Batidas por minuto (BPM)	Numérico (Real)	-
Duração	Duração da faixa em milissegundos	Numérico (Inteiro)	-

Fonte: Adaptado de Spotify for Developers Documentation (2024).

É importante ressaltar que para fazer os clusters, utilizamos o método min-max para transformar os dados de Volume, Tempo e duração assim todas as variáveis numéricas ficariam entre 0 e 1.

2.2 Métodos de agrupamento

Inicialmente, utilizaremos um método hierárquico para explorar os dados e decidir o número de grupos (*clusters*) e depois faremos o agrupamento usando o método k-means que é um método não hierárquico. O método é composto por quatro etapas. Primeiramente é feita a escolha aleatória de k centroides dos pontos de amostra como centros iniciais do cluster. Em seguida, a atribuição de cada amostra ao centroide mais próximo. Na terceira etapa, a alteração dos centroides para o centro das amostras que lhe foram conferidas. Por fim, a repetição da segunda e terceira etapa, até que a atribuição do cluster não seja alterada ou uma tolerância seja definida pelo usuário ou um número máximo de iterações seja realizado (RASCHKA, 2015). A figura 1 ilustra como é feito o agrupamento.

Figura 1 – Ilustração do passo a passo do método K-Means




Figura 5.14. Primeiros Passos do Algoritmo.




Figura 5.15. Passos Subseqüentes do Algoritmo.

Fonte: GOLDSCHIDT; PASSOS (2005)

3 Análise exploratória

Antes de fazer o agrupamento, vamos entender um pouco sobre algumas variáveis e suas relações, isso facilita para entender a análise de resultados, uma vez que os gráficos e tendências encontrados na análise exploratória ajudarão a descrever as tendências estilísticas e padrões temáticos da discografia de Taylor Swift. Na figura 2 podemos ver a distribuição das variáveis

Vemos que a energia e volume tem uma distribuição bem semelhantes, uma vez que sua mediana está bem próxima, enquanto tempo (número de batidas por minuto padronizado para ficar entre 0 e 1) e valência, que diz se uma música é triste ou feliz com base


Figura 2 – Boxplot das variáveis



em seu valor tem uma mediana quase igual. Nota-se alguns outliers nas variáveis duração, volume e dançabilidade sendo principalmente na primeira. Antes de ser normalizada a amplitude da variável já tinha uma dispersão muito grande e a padronização escolhida não trata os outliers. A música *All Too Well (10 minutes version)* é a mais longa de toda a discografia de Taylor Swift com 10 minutos e 13 segundos enquanto *I Look at People's Windows* possui 2 minutos e 18 segundos

Abaixo, vemos a correlação entre as variáveis numéricas da base de dados.

Figura 3 – Correlação entre as variáveis



Utilizamos a correlação de Pearson para investigar o comportamento linear conjunto entre as variáveis. A partir do gráfico, observamos que a acústica (*acousticness*) apresenta uma forte correlação negativa com o volume (*loudness*) e a energia, sugerindo que músicas com maior presença de instrumentos acústicos tendem a ter menor volume e energia, sendo, portanto, mais suaves.

Por outro lado, energia e volume mostram uma correlação positiva forte, indicando que músicas mais enérgicas tendem a ser mais altas. A energia também apresenta uma correlação fraca com o *tempo*. A variável valência, que indica o tom emocional da música (feliz ou triste), exibe uma correlação positiva significativa com a energia e o volume, além de uma correlação fraca e positiva com o *tempo*, indicando que músicas mais felizes tendem a ser mais altas, mais enérgicas e ligeiramente mais rápidas em termos de batidas por minuto. Em contraste, músicas mais tristes parecem ter uma leve tendência a utilizar mais instrumentos acústicos e a serem mais longas. Esse padrão faz sentido, pois as músicas mais longas na base de dados, como *All Too Well (10 Minute Version)* do álbum *Red (Taylor's Version)* e *Dear John*, são canções sobre términos de relacionamento.

A dançabilidade apresentou alguns resultados contraintuitivos, como uma correlação negativa e fraca com o *tempo* (batidas por minuto) e ausência de relação com a energia e o volume da música. Esses resultados podem ser explicados pelo fato de que, embora Taylor Swift seja uma artista pop, ela não possui muitas músicas com perfil dançante.


4 Decidindo o número de Clusters

O método k-means exige que seja decidido o número de clusters antes de se aplicar o algoritmo para fazer o agrupamento. Utilizamos três métodos para a decisão da quantidade de clusters: O primeiro sendo o Dendrograma seguido de uma análise visual, o segundo sendo o método do Cotovelo que é um critério mais objetivo para obter o número de clusters e o terceiro é utilizar um cluster para cada álbum, que seria um agrupamento natural existente, uma vez que espera-se que as músicas dentro dos mesmos álbuns tenham características parecidas.

4.1 Dendrograma


Fizemos o dendrograma utilizando três métodos de ligação: Simples, completa e média.

Figura 4 – Dendrogramas das músicas de Taylor Swift utilizando ligação simples, completa e média respectivamente




A ligação completa foi a que ficou mais harmônica, então consideraremos ela. Observando somente esse dendrograma consideramos que com 5 grupos ($k=5$) os dados estão suficientemente agrupados.

Figura 5 – Dendrograma utilizando ligação completa e considerando $k=5$



4.2 Critério do Cotovelo

Figura 6 – Gráfico do cotovelo



O método do cotovelo consiste em encontrar o elemento que ao mesmo tempo minimize o número de clusters e a soma das distâncias dentro dos clusters. Tal valor será o que está no "cotovelo" do gráfico. Assim, pelo critério do cotovelo $k = 4$ é a quantidade ideal de clusters.

5 Análise de Resultados

A tabela 3, exibida abaixo mostra os resultados dos agrupamentos com diferentes números de centroides no método k-means

Tabela 3 – Análise de Soma dos Quadrados e R^2 para Diferentes Números de Clusters

Número de Clusters	Soma de Quadrados	Valor	R^2
4	Total	68.20	57.00%
	Dentro dos Grupos	29.32	
	Entre os Grupos	38.88	
5	Total	68.20	60.90%
	Dentro dos Grupos	26.67	
	Entre os Grupos	41.52	
11	Total	68.20	74.50%
	Dentro dos Grupos	17.35	
	Entre os Grupos	50.85	

Fonte: Elaboração própria.

Nosso objetivo é que os clusters capturem características similares dentro de cada grupo e se mantenham distintos entre si. Em outras palavras, buscamos minimizar a

variabilidade dentro dos grupos e maximizar a variabilidade entre eles, o que resultaria em um melhor desempenho das métricas ao utilizarmos quatro clusters. No entanto, essas medidas são sensíveis ao número de clusters. À medida que o número de clusters aumenta, é esperado que a variabilidade dentro dos grupos também aumente, enquanto a variabilidade entre os grupos e o valor de R^2 diminuam.

A figura abaixo apresenta os gráficos dos clusters nas duas primeiras componentes principais.

Figura 7 – Componentes principais para o cluster com 4 centroides




Figura 8 – Componentes principais para o cluster com 5 centroides





Figura 9 – Componentes principais para o cluster com 11 centroides



Cada gráfico mostra a distribuição das músicas nas duas primeiras componentes principais (Dim1 e Dim2), que juntas explicam aproximadamente 61

Na análise de clusters com 11 centros, conforme ilustrado no Apêndice 1, é possível observar que algumas versões diferentes de uma mesma música acabaram alocadas em clusters distintos. Exemplos disso incluem *Teardrops on My Guitar (Pop Version)* e *Teardrops on My Guitar (Radio Version)*, assim como *Bad Blood feat. Kendrick Lamar* e *Bad Blood*.

6 Conclusão

Neste estudo, aplicamos técnicas de análise de agrupamento para explorar a discografia de Taylor Swift, buscando identificar padrões estilísticos e temáticos ao longo de sua carreira. Utilizando a API do Spotify, coletamos dados técnicos sobre cada música, selecionamos variáveis relevantes e realizamos o pré-processamento necessário para aplicar o método de agrupamento k-means.

Durante a análise exploratória dos dados, identificamos alguns erros de medida nos indicadores fornecidos pelo Spotify, evidenciando que a plataforma ainda precisa aprimorar certos aspectos técnicos. Esses erros afetaram a análise, pois músicas com características distintas foram classificadas em um mesmo cluster devido a valores similares nas variáveis escolhidas.

Uma questão central ao iniciar o trabalho era se o algoritmo de agrupamento seria capaz de capturar as nuances e subjetividades das músicas de uma das mais renomadas compositoras em língua inglesa do século XXI, mesmo sem acesso às letras das músicas — elemento fundamental para esse tipo de distinção.

Ainda assim, o agrupamento com quatro centroides, selecionado com base no método do cotovelo, mostrou o melhor desempenho na análise da variabilidade, apresentando um R^2 satisfatório e maior coesão interna. Observamos que músicas de gênero pop e com maior energia foram agrupadas nos clusters 1 e 2, enquanto músicas de gênero indie, mais tristes e lentas, concentraram-se nos clusters 3 e 4.

Esses agrupamentos permitiram uma interpretação mais rica e objetiva da evolução da carreira de Taylor Swift, evidenciando que, ao longo do tempo, ela diversificou seu estilo, explorando diferentes gêneros e temas em cada fase.

7 Considerações finais

A API do Spotify se mostrou de fácil utilização, e o fato de os dados estarem normalizados facilitou nossa análise. Embora existam vários estudos de análise de agrupamento utilizando dados do Spotify, a maioria considera dados de diversos artistas ou playlists em suas bases, o que possivelmente minimiza os erros de classificação encontrados ao lidar com um único artista.

Referências

CARVALHO, Daiana Aparecida de; VALENTE, Gerson de Freitas Silva. Algoritmo K-Means para avaliação de aceitação sensorial de iogurtes light elaborados com Xilitol e Estévia. *Brazilian Journal of Development*, Curitiba, v. 7, n. 7, p. 74154-74163, jul. 2021. DOI: 10.34117/bjdv7n7-546. Recebido em: 26 jun. 2021. Aceito em: 26 jul. 2021. Nenhuma citação no texto.

CNN BRASIL. Taylor Swift é a artista mais ouvida da história do Spotify; veja ranking. *CNN Brasil*, 1º nov. 2023. Disponível em: <<https://www.cnnbrasil.com.br/entretenimento/taylor-swift-e-a-artista-mais-ouvida-da-historia-do-spotify-veja-ranking/>>. Acesso em: 14 nov. 2024. Nenhuma citação no texto.

DUARTE, Samuel Ricardo Nobre. Um guia para agrupamento com pacote cluster do R utilizando dados do Spotify. 2023. Monografia de Graduação apresentada ao Curso de Graduação em Estatística do Centro de Ciências Exatas e da Terra da Universidade Federal do Rio Grande do Norte, como requisito parcial para a obtenção do grau de Bacharel em Estatística. Universidade Federal do Rio Grande do Norte, Centro de Ciências Exatas e da Terra, Curso de Graduação em Estatística. Nenhuma citação no texto.

FINK. O fenômeno Swift: o impacto de Taylor na cultura e na economia. *Fink*, 2024. Disponível em: <<https://www.fink.pt/o-phenomeno-swift-o-impacto-de-taylor-na-cultura-e-na-economia/>>. Acesso em: 14 nov. 2024. Nenhuma citação no texto.

GOLDSCHMIDT, Ronaldo; PASSOS, Emmanuel. *Data mining: um guia prático*. 4. reimpr. Rio de Janeiro: Elsevier, 2005. ISBN 85-352-1877-7. Nenhuma citação no texto.

JOHNSON, Richard A.; WICHERN, Dean W. *Applied Multivariate Statistical Analysis*. 6. ed. Pearson, 2007. Nenhuma citação no texto.

PILATTI, Rodrigo. Segmentação comportamental de utilizadores de cartão de crédito utilizando o algoritmo de máquina não supervisionado k-means. 2021. Trabalho de conclusão de curso (Especialista em Inteligência Artificial e Big Data) – Departamento de Ciências de Computação, Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos, 2021. Orientadora: Profa. Dra. Kalinka Regina Lucas Jaquie Castelo Branco. Nenhuma citação no texto.

ROLLING STONE. Taylor Swift’s Eras Tour: Highest-Grossing of All Time, Surpassing \$1 Billion. *Rolling Stone*, 1º nov. 2023. Disponível em: <<https://www.rollingstone.com/music/music-news/taylor-swift-eras-tour-highest-grossing-all-time-1-billion-1234921647/>>. Acesso em: 14 nov. 2024. Nenhuma citação no texto.

R CORE TEAM. spotifyr: R interface to the Spotify Web API. Versão 2.2.4. Disponível em: <<https://www.rdocumentation.org/packages/spotifyr/versions/2.2.4>>. Acesso em: 14 nov. 2024. Nenhuma citação no texto.

SOUSA, Maria Cristina Cordeiro. Uma análise do algoritmo K-means como introdução ao Aprendizado de Máquinas. 2019. 74 f. TCC (Graduação) - Curso de Matemática, Universidade Federal do Tocantins, Araguaína, 2019. Nenhuma citação no texto.

SPOTIFY. Spotify Web API: Get Audio Features. Disponível em: <<https://developer.spotify.com/documentation/web-api/reference/get-audio-features>>. Acesso em: 14 nov. 2024. Nenhuma citação no texto.

SOURAAV. Spotify Popularity Analysis. Disponível em: <<https://rpubs.com/souraav/SpotifyPopularity>>. Acesso em: 14 nov. 2024. Nenhuma citação no texto.

THOMPSON, Charlie; PARRY, Josiah; PHIPPS, Donal; WOLFF, Tom. R Wrapper for ‘Spotify’ Web API. Disponível em: <<https://www.rcharlie.com/spotifyr/>>. Acesso em: 14 nov. 2024. Nenhuma citação no texto.

VERI, Lorayne; KLEINA, Mariana; MACENO, Marcell Mariano Correa; BELALCAZAR, Paola Andrea Rico. Clusterização para recomendação de músicas para um usuário no Spotify utilizando o software R. *Anais do XIII Congresso Brasileiro de Engenharia de Produção*, 2023. Nenhuma citação no texto.